Práctica 1: Gestión y Predicción de Finanzas Personales

Diego Esclarín Sofía Contreras

10 de marzo de 2026

Universidad Rey Juan Carlos
Campus de Móstoles

Aplicaciones de Inteligencia Artificial
Grado en Ingeniería en Inteligencia Artificial
Universidad Rey Juan Carlos
Curso 2025–26

Índice

1. Introducción **2**

2. Contexto **3**
2.1. Métricas 3

3. Estado del Arte **4**

4. Propuesta de Solución **5**
4.1. Preprocesamiento e Ingeniería de Características 5
4.2. Modelos de Análisis y Predicción Implementados 5
4.3. Análisis de Resultados y Validación 6
4.4. Selección del Modelo y Desempeño del MVP 8

5. Conclusiones y Trabajo Futuro **9**

1. Introducción

Esta memoria documenta el desarrollo de la Práctica 1, cuyo objetivo es diseñar e implementar modelos de aprendizaje automático capaces de predecir el comportamiento de las finanzas personales. Específicamente, nos enfocamos en estimar el volumen de gastos futuros basándonos en variables históricas y patrones de consumo.

Para el desarrollo del presente proyecto es importante aclarar que los datos analizados son sintéticos y representan el comportamiento económico de una **única persona**. La decisión de aislar la información a nivel individual se basa en un requisito de diseño: el modelo final en producción se reentrenará dinámicamente con los datos de cada usuario. Esto garantiza una alta personalización predictiva sin mezclar datos de diferentes individuos, preservando tanto la precisión del perfil de gasto como la privacidad del usuario.

2. Contexto

La gestión de las finanzas personales se ha vuelto una tarea fundamental debido a la gran cantidad de datos y transacciones que manejamos mensualmente. En este escenario, ser capaz de predecir picos de gasto o identificar patrones de consumo es clave para mejorar la capacidad de ahorro y asegurar una estabilidad económica a medio y largo plazo.

El problema que se aborda en esta práctica consiste en pronosticar el gasto mensual de un usuario utilizando datos históricos. Aunque tradicionalmente este control se hacía de forma manual, el uso de técnicas de Inteligencia Artificial permite automatizar el proceso y encontrar tendencias o estacionalidades que no son evidentes a simple vista. El objetivo final es desarrollar un modelo capaz de estimar el gasto total de los próximos meses analizando los hábitos recurrentes y la rutina financiera del usuario.

2.1. Métricas

Para evaluar la precisión y fiabilidad de estas predicciones, se han seleccionado las siguientes métricas:

- **Error Absoluto Medio (MAE):** Indica la diferencia promedio directa entre la predicción y el gasto real del usuario a final de mes, facilitando una interpretación monetaria inmediata del error.
- **Raíz del Error Cuadrático Medio (RMSE):** Fundamental para penalizar errores de gran magnitud, algo vital cuando una desviación excesiva en el presupuesto supone un riesgo financiero inasumible.
- **R-cuadrado (R^2):** Permite comprobar en qué medida las variables definidas (gasto acumulado y promedios históricos) explican realmente la variabilidad y la cifra final del gasto mensual.

3. Estado del Arte

La previsión financiera personal a través de series temporales conforma en la actualidad un ecosistema dinámico investigado activamente. Al investigar los estándares actuales en la predicción de series temporales financieras, destaca el modelo **SARIMAX** como una de las herramientas más robustas y diferenciales en la literatura técnica para integrar componentes estacionales y variables externas [1]. Este modelo es fundamental porque proporciona un marco estadístico sólido para este tipo de predicciones en entornos cambiantes.

Investigaciones más recientes subrayan la vigencia de este enfoque y su evolución hacia modelos híbridos. Por ejemplo, estudios recientes demuestran cómo el uso de redes neuronales recurrentes, concretamente las **LSTM**, permiten capturar dependencias a largo plazo superando en ocasiones a los modelos econométricos tradicionales como ARIMA en la predicción de series complejas [2]. En el ámbito específico de las finanzas personales, trabajos actuales como *WONGA* proponen sistemas de seguimiento y predicción de gastos basados en modelos de aprendizaje automático altamente eficientes [3].

Históricamente, los enfoques algorítmicos han partido de la **Regresión Lineal (LR)** como *baseline* o punto de referencia inicial para medir el éxito de cualquier mejora posterior. En desarrollos modernos, es estándar la implementación de modelos de gestión de finanzas personales que analizan el comportamiento del consumidor para predecir picos de gasto [4], [5]. Estos se combinan frecuentemente con modelos de ensamble basados en árboles de decisión, tales como *Random Forest*, *XGBoost* o *HistGradientBoosting*, que ofrecen la flexibilidad necesaria para capturar relaciones no lineales y hábitos fluctuantes [6].

4. Propuesta de Solución

El desarrollo de la solución comienza con la generación de un conjunto de datos sintético. Para ello, se ha utilizado el modelo de lenguaje **Claude Sonnet 4.6 Extendido** para simular un historial de transacciones financieras basado en la descripción de los gastos típicos de un alumno universitario (transporte, material académico, ocio, facturas recurrentes y becas/ingresos variables). Esta base de datos sirve como fundamento para entrenar modelos que capturen hábitos de consumo reales en un entorno controlado.

4.1. Preprocesamiento e Ingeniería de Características

Debido a la naturaleza del gasto personal, caracterizado por una fuerte estacionalidad y por patrones repetitivos, se ha diseñado un proceso de preprocesamiento antes del entrenamiento de los modelos:

- **Limpieza y Formateo:** Se procedió a la estandarización del dataset mediante la conversión temporal a `datetime` y la normalización de la columna *Amount* (eliminación de €, ajuste de decimales y tipos `float`). Además, se regularizaron los signos de flujo de caja y se filtraron categorías ruidosas (ej. *Leisure*) para asegurar la calidad de la señal de entrenamiento.

- **Ingeniería de Características:** Se transformó el histórico en una serie mensual agregada. Se extrajeron indicadores de estacionalidad (trimestres y meses críticos como verano o diciembre) y se generaron retardos (*Lags* de hasta 12 meses) para modelar la recurrencia del gasto. La tendencia se capturó mediante estadísticas rodantes (EMA de 3 y 6 meses) combinadas con imputación *back-fill* para nulos.

- **Transformaciones Específicas:**
  - **ARIMA/SARIMAX:** Aplicación de valor absoluto y transformación logarítmica `log1p` ($\ln(1+x)$) para estabilizar la varianza de la serie y facilitar la linealización de relaciones ante grandes variaciones de gasto.
  - **LSTM:** Normalización mediante escalado Min-Max en el rango $[0, 1]$ y reestructuración de la entrada en ventanas deslizantes de 3 meses, permitiendo a la red aprender la "memoria"secuencial de la serie temporal.

4.2. Modelos de Análisis y Predicción Implementados

El entrenamiento de esta solución se basó en una experimentación comparativa abordando:

1. **Linear Regression (Baseline)**: Como punto de partida de referencia para certificar las posteriores ganancias de información.

2. **XGBoost, Random Forest e HistGradientBoosting**: Familia de métodos de ensamblado basados en árboles de decisión, que actúan de manera similar resolviendo las relaciones no-lineales subyacentes presentes en la lógica de las características estacionales *One-Hot* y los lags retardados.

3. **ARIMA y SARIMAX**: Alternativas analítico-estadísticas clásicas focalizadas exclusivamente en la regresión temporal intrínseca frente al historial de observaciones directas y la autocorrelación de sus rezagos sin tantas características contextuales combinadas.

4. **Voting Regressor (Ensemble final)**: Combinación agregativa orientada específicamente a disminuir la sensibilidad a la varianza y estabilizar la predicción sobre aquellos modelos ensamble con los índices absolutos de error (MAE) más eficientes. En un futuro se podría implementar usando los modelos de ensamble con los mejores índices de error como por ejemplo **Random Forest** y **ARIMA** que hemos visto que son los más robustos y que mejoran el MAE.

5. **Recurrent Neural Network (LSTM)**: Un enfoque profundo para encontrar memoria secuencias a largo/corto plazo sobre las capas recursivas ajustadas por épocas de validación cruzada.

Para sustentar documentalmente la evolución algorítmica y su comportamiento durante el entrenamiento o en el ciclo final de test, se añaden a continuación las pertinentes capturas procedentes de la ejecución final del estudio:

4.3. Análisis de Resultados y Validación

Tras la implementación de los modelos descritos, se procedió a una validación experimental para contrastar su desempeño bajo distintas condiciones de datos, permitiendo justificar la elección del modelo final.

En la Figura 1, se presenta la comparativa inicial utilizando el dataset bruto. El resultado evidencia la ineficacia de la Regresión Lineal ante datos con alta varianza y presencia de valores atípicos, presentando un error (MAE) que triplica al de los modelos de ensamble. Esto ratifica que la relación entre las características temporales y el gasto no es lineal. Que los modelos hayan funcionado tan mal en general se debe a que el dataset original cambia los ingresos a partir del mes de septiembre, lo que coincide con los datos de test.

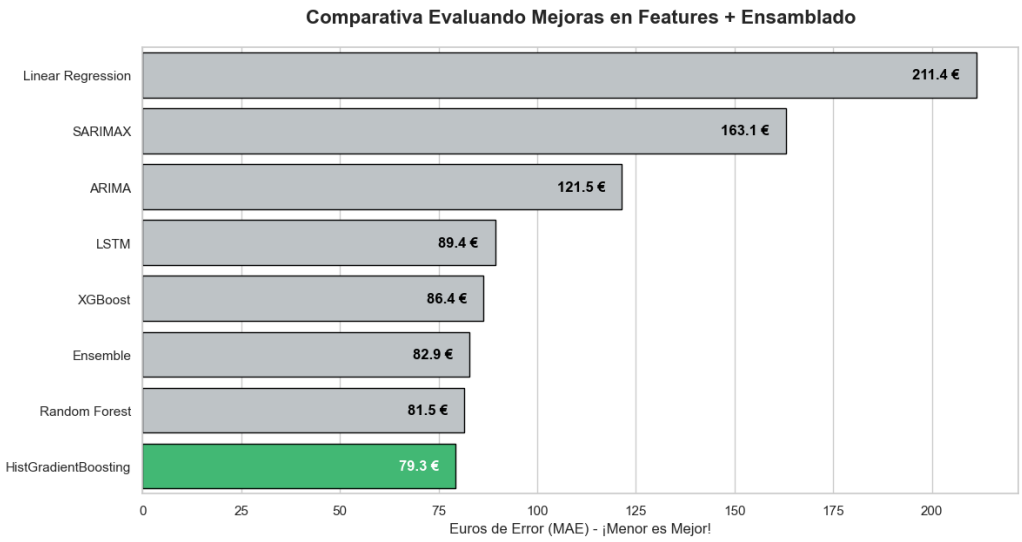

Figura 1: Evaluación del MAE con datos originales: se observa la vulnerabilidad del modelo lineal frente a la robustez de los algoritmos de árboles.

Posteriormente, truncamos el dataset original hasta el mes de septiembre que es el mes en el que cambian los ingresos y aumentamos el dataset 4000 y 8000 filas. Como muestra la Figura 2, si bien esta limpieza reduce drásticamente el error del modelo base (LR), los modelos de *Random Forest* y *Boosting* mantienen su superioridad. Esto demuestra que su capacidad predictiva no depende solo de la ausencia de valores extremos, sino de la captura de patrones cíclicos mediante los *lags* generados [1], [5].

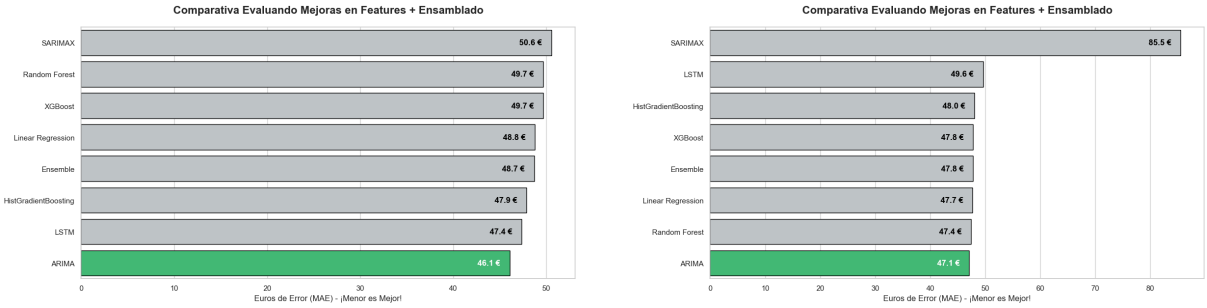

(a) 4.779 filas.

(b) 8.779 filas.

Figura 2: Impacto del aumento de datos en el error (MAE): mejora de la convergencia en modelos simples y consolidación de los modelos de ensamble como los más robustos.

4.4. Selección del Modelo y Desempeño del MVP

Finalmente, se seleccionó el modelo **Random Forest** debido a su estabilidad y precisión consistente en ambas pruebas. La Figura 3 ilustra el desempeño final en el conjunto de test, donde la línea de predicción captura con éxito la estacionalidad y las fluctuaciones del gasto real [3]. Este resultado visual confirma que la estrategia de preprocesamiento y el algoritmo seleccionado son capaces de anticipar con éxito el comportamiento económico del usuario.

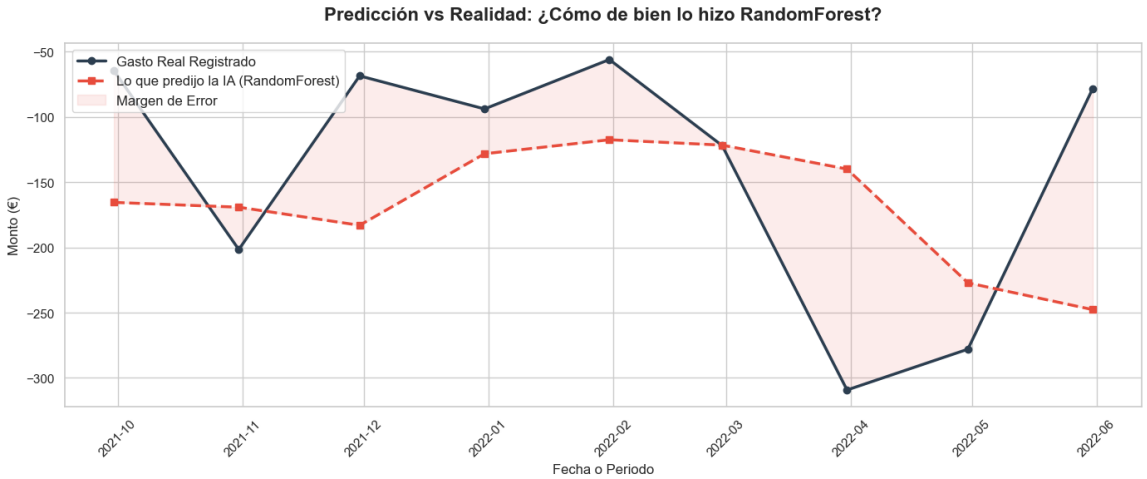

Figura 3: Contraste entre valores reales y predicción final del MVP (Random Forest). Se observa una alta correlación en la tendencia temporal [3].

5. Conclusiones y Trabajo Futuro

Tras desarrollar las distintas fases de ingeniería de características (añadiendo descomposiciones estacionales, medias móviles e indicadores binarios), queda claro que la calidad de estas variables es fundamental para mejorar métricas como el R^2 y el MAE. En este tipo de problemas, la preparación de los datos resulta más determinante que la arquitectura del propio modelo.

Como trabajo futuro, seguiremos iterando sobre los modelos **Random Forest** y **ARIMA**, ya que han demostrado ser los enfoques más robustos durante las pruebas. Cabe destacar que, aunque el modelo **ARIMA** presenta una alta sensibilidad inicial (con el dataset original con menos de 1000 filas) y requiere un histórico denso para ser preciso, su rendimiento mejora notablemente a medida que aumenta el volumen de datos. Esperamos que, con bases de datos más extensas, este modelo se consolide como la opción más fiable para el pronóstico a largo plazo.

Referencias Bibliográficas

[1] J. Banaś y K. Utnik-Banaś, «Evaluating a seasonal autoregressive moving average model with an exogenous variable for short-term timber price forecasting,» *Forest Policy and Economics*, vol. 131, pág. 102 564, 2021.

[2] S. Kuznetsov. «Evaluation of LSTM Networks for Stock Price Forecasting: A Benchmark Against traditional econometric models (ARIMA and PROPHET).»

[3] M. I. R. Uyanahewa, M. B. D. N. Bandara y H. A. V. V. Hapugala, «WONGA: The Future of Personal Finance Management–A Machine Learning-Driven Approach for Predictive Analysis and Efficient Expense Tracking,» en *2023 4th International Conference for Emerging Technology (INCET)*, IEEE, 2023, págs. 1-6.

[4] F. Kooti, K. Lerman, L. M. Aiello, M. Grbovic, N. Djuric y V. Radosavljevic, «Portrait of an online shopper: Understanding and predicting consumer behavior,» en *Proceedings of the ninth ACM international conference on web search and data mining*, 2016, págs. 205-214.

[5] S. G. Kaushik, S. S. Kashyap y S. Reddy, «Personal Finance Management and Prediction using ML Algorithms,» en *2024 8th International Conference on Computational System and Information Technology for Sustainable Solutions (CSITSS)*, IEEE, 2024, págs. 1-5.

[6] D. Pavithra, N. Dhivyaprabha, K. Shreenithi y C. C. Theshika, «Personal Finance Tracker with Spending Behavior Analysis,» en *2025 5th International Conference on Evolutionary Computing and Mobile Sustainable Networks (ICECMSN)*, IEEE, 2025, págs. 1824-1832.